

Agent 可观测与追踪：Trace、指标与回放

语言策略：code (Java / Python / TypeScript)

TL;DR

- 普通服务监控只回答“接口慢不慢”，Agent 可观测还需回答“为什么这么走”。
- 最小可用能力是三项：**Trace 记录决策轨迹、指标聚合趋势、回放复现问题**。
- 可观测不是上线后补，而是在 Agent Loop 里埋点：LLM 调用、工具调用、状态变更、审批事件都必须留痕。

1. 与普通服务可观测的区别

维度	普通服务	Agent
一次请求	一次调用	多轮 LLM + 多轮工具
关键对象	接口延迟	轨迹、工具、上下文
错误定位	堆栈	哪一轮、哪个工具、哪段上下文
复现	重放请求	重放完整状态与上下文
成本	机器资源	Token 与工具费用

2. Trace 语义模型

Span 类型	记录内容
task	task_id、用户、租户、目标、最终状态
agent_loop	轮次、本轮思考摘要、停止原因
llm_call	model、prompt_version、输入输出 Token、延迟、采样参数
tool_call	工具名、参数摘要、返回摘要、风险等级、审批状态
memory	写入/读取的 memory key 与来源
retrieval	查询、命中数、rerank 前后顺序

一个 Span 最小属性：trace_id、task_id、parent_span_id、span_id、node、model、prompt_version、tool_name、status、latency_ms、input_tokens、output_tokens。

上下文必须脱敏后记录：密钥、手机号、邮箱、身份证号等先做 redaction，再写日志或导出。

3. 指标清单

指标	含义	告警建议
task_success_rate	任务成功率	低于 0.90 告警
avg_steps	平均 Agent 轮次	突增说明计划变差
tool_error_rate	工具调用错误率	超过 0.05 告警
approval_rate	高危动作审批率	突增要排查注入
tokens_per_task	单任务 Token	超预算告警
cost_per_task	单任务成本	超预算告警
p95_task_latency	任务 P95 延迟	超 SLO 告警
loop_exit_by_limit	因轮次上限退出的比例	持续大于 0.01 要修

4. 回放与调试

- 保存每个任务的输入、上下文快照、工具返回和最终输出；
- 按 task_id 重放，注入同一份上下文，观察模型是否做出不同决策；
- 回放数据必须脱敏并按保留周期清理；
- 生产事故复盘顺序：看最终输出 → 看工具轨迹 → 看上下文 → 重放验证。

5. Python 版采集器

```
1 from dataclasses import dataclass, field
2
3 @dataclass
4 class AgentSpan:
5     trace_id: str
6     task_id: str
7     span_id: str
8     parent_span_id: str | None
9     node: str
10    model: str | None = None
11    prompt_version: str | None = None
12    tool_name: str | None = None
13    status: str = "ok"
14    latency_ms: int = 0
15    input_tokens: int = 0
16    output_tokens: int = 0
17
18 class AgentTelemetry:
19     def __init__(self) -> None:
20         self.spans: list[AgentSpan] = []
21
22     def record(self, span: AgentSpan) -> None:
23         self.spans.append(span)
24
25     def task_count(self) -> int:
26         return len([s.task_id for s in self.spans])
27
28     def tool_error_rate(self) -> float:
29         tool_spans = [s for s in self.spans if s.tool_name]
30         errors = [s for s in tool_spans if s.status == "error"]
31         return len(errors) / len(tool_spans) if tool_spans else 0.0
32
33     def total_tokens(self) -> int:
34         return sum(s.input_tokens + s.output_tokens for s in self.spans)
```

6. 典型故障排查表

现象	先查什么	常见原因
任务变慢	P95、平均步数、工具延迟	计划变长、工具超时、模型切换
成功率突降	失败任务轨迹与上下文	Prompt/工具描述变更、知识库污染
成本突增	单任务 Token、缓存命中率	上下文膨胀、路由到贵模型
工具报错多	tool_error_rate 按工具分列	Schema 变更、权限不足
循环退出多	loop_exit_by_limit	目标不清晰、工具返回不可用

7. 延伸阅读

- [大模型网关](#)
- [Agent 部署与发布](#)
- [Agent 评测体系](#)