

Agent 部署与发布：从灰度到回滚

语言策略：code (Java / Python / TypeScript)

TL;DR

- Agent 的发布单元不止代码：**Prompt、工具、模型路由、记忆策略都会改变线上行为**，必须一起版本化。
- 推荐路径：离线回归 → 影子流量 → 灰度 → 全量；每个阶段都有可观测指标和回滚条件。
- 部署前先回答三个问题：任务能不能幂等？跑一半断了怎么办？回滚时旧 Prompt 和旧工具是否还在？

1. 部署形态

形态	适用场景	注意点
同步 API 服务	交互式助手	需要流式、超时与取消
异步任务队列	长任务、批处理	任务状态、幂等、死信队列
定时/事件驱动 Worker	巡检、告警处理	并发控制、去重
边端/混合部署	数据不出域	模型版本与配置下发

2. 发布单元与版本化

发布单元	版本标识	回滚方式
应用代码	Git commit / 镜像 tag	回滚镜像
System Prompt	prompt_version	配置回滚
工具 Schema / Skill	toolset_version	注册表回滚
模型路由策略	route_version	网关配置回滚
评测集与门禁	eval_version	随发布记录关联

发布包必须记录以上五个版本，Trace 中也要带上 prompt_version 与 toolset_version，否则线上问题无法归因。

3. 发布流水线

1 代码/配置变更
2
3
4 离线回归（成功率和工具准确率门禁）
5
6
7 影子流量（只记录，不影响用户）
8
9
10 灰度 5% → 25% → 100%
11
12
13 观察 P95、成功率、成本、危险动作率
14
15
16 通过则全量，否则自动回滚

灰度期间高危工具默认只读或审批升级；灰度时间不少于一个完整业务周期。

4. 运行时要求

- 健康检查：/health 同时检查模型供应商、向量库和工具依赖；
- 超时与取消：Agent Loop 总超时、单工具超时、用户取消；
- 幂等：同一 task_id 重复提交只执行一次；

- 限流：按用户、租户、工具设置配额；
- 审计：部署事件、配置变更、回滚事件全部留痕。

5. Python 版服务骨架与容器化

```
1 from dataclasses import dataclass
2 from typing import Protocol
3
4 @dataclass
5 class AgentRunRequest:
6     task_id: str
7     input: str
8     prompt_version: str
9     user_id: str
10
11 @dataclass
12 class AgentRunResponse:
13     task_id: str
14     status: str
15     result: str
16     elapsed_ms: int
17
18 class AgentRuntime(Protocol):
19     def run(self, request: AgentRunRequest) -> AgentRunResponse: ...
20     def health(self) -> dict: ...
21
22 from fastapi import FastAPI
23
24 def build_app(runtime: AgentRuntime) -> FastAPI:
25     app = FastAPI()
26
27     @app.post("/run")
28     def run(request: AgentRunRequest) -> AgentRunResponse:
29         return runtime.run(request)
30
31     @app.get("/health")
32     def health() -> dict:
33         return runtime.health()
34
35     return app
```

```
1 FROM python:3.12-slim
2 WORKDIR /app
3 COPY requirements.txt .
4 RUN pip install --no-cache-dir -r requirements.txt
5 COPY . .
6 EXPOSE 8000
7 CMD ["uvicorn", "main:app", "--host", "0.0.0.0", "--port", "8000"]
```

```
1 健康检查: GET /health
2 发布命令: docker build -t agent-service:<git-sha> . && docker push
3 回滚命令: kubectl set image deploy/agent-service agent-service=agent
4 -service:<previous-sha>
```

6. 回滚决策表

信号	阈值示例	动作
任务成功率	低于基线 5 个百分点	立即回滚
P95 延迟	超过 SLO 的 120	
危险动作率	出现一次未授权高危动作	冻结 + 回滚
单任务成本	超过预算 130	
用户投诉	同主题短时激增	暂停灰度

7. 上线 Runbook 检查单

- 发布包记录了代码、Prompt、工具、模型路由、评测集五个版本；
- 离线回归门禁通过；
- 回滚镜像和旧配置可用；
- 高危工具已配置审批；
- 监控面板和告警已就绪；
- 灰度比例、时长、回滚触发条件已明确；
- 事故联系人已确认。

8. 延伸阅读

- [大模型网关](#)
- [Agent 可观测与追踪](#)
- [AI 应用系统设计](#)