

Agent 术语表与概念边界

术语表

基础与系统

术语	一句话定义	容易混淆的点
AI Agent	能感知环境、制定计划、调用工具、执行动作并在反馈中持续运行的软件系统	不是所有接 LLM 的应用都是 Agent
Agent Loop	Agent 的核心运行循环：读取上下文 → LLM 推理 → 调用工具 → 观察结果 → 继续，直到完成或触发停止条件	Loop 是机制，ReAct 是使用 Loop 的一种范式
Chatbot	以对话为主要交互形式、通常不主动调用外部工具改变外部世界的应用	有对话界面不等于有 Agent
Workflow	预先定义节点与边的固定执行流程，LLM 只作为其中若干节点	控制权在图结构里，不在模型手里
Agentic Workflow	全局用 Workflow 管住结构，局部不确定节点嵌入 Agent 子循环的混合形态	不是“纯 Agent”
RAG	检索增强生成：从外部知识源检索相关片段，再交给 LLM 生成回答	RAG 是知识接入方式，不是记忆系统的全部
LLM	大语言模型，负责理解与生成	不是系统本身
Function Calling	模型输出结构化“调用意图”，由外部程序决定是否执行并返回结果的机制	模型只生成意图，不直接执行函数
Tool	让 LLM 影响外部世界的可执行能力：查库、发信、跑代码等	Tool 是能力，Function Calling 是调用协议
Tools 注册	把工具名、JSON Schema、用途和禁用场景描述注入上下文的工程动作	description 质量决定调用准确率
JSON Schema	结构化描述参数类型、必填项与约束的契约	它是数据格式，不是通信协议
Structured Outputs	模型按给定 Schema 输出结构化结果的约束能力	它约束输出，不约束执行
MCP	Model Context Protocol：基于 JSON-RPC 2.0 的工具/资源/提示词接入协议	MCP 解决“怎么接入”，Function Calling 解决“怎么表达调用意图”
Agent Skills	以 SKILL.md 为核心的可复用经验包，延迟加载完整指令	Skills 是白盒经验包，Toolkit 是黑盒高阶函数
Prompt Engineering	通过改写提示词直接影响模型输出的工程方法	只解决“单次怎么问”

能力与工程

术语	一句话定义	容易混淆的点
Context Engineering	管理模型在每轮决策时看到什么信息的系统方法，包括系统提示词、记忆、工具描述、检索内容的动态组装	解决“每轮该喂什么”
Harness Engineering	围绕模型外部的执行环境做工程：循环、工具、权限、上下文、可观测、错误处理	瓶颈常在 Harness，不在模型
Memory	Agent 保存和检索历史与经验的能力，分短期/长期	Memory 是“记住了什么”，RAG 是“去外部查什么”
Short-Term Memory	当前任务范围内的对话与执行轨迹，通常放上下文	超出上下文即开始失真
Long-Term Memory	跨任务持久化的用户偏好、事实和和经验	需要检索、更新、遗忘机制
Planning	把目标拆成步骤并动态调整的能力	计划不是写死的流程
ReAct	推理与行动交替进行的范式	适合路径不确定的任务
Plan-and-Execute	先全局计划、再分步执行的范式	适合长任务但动态调整弱
Reflection	让模型对结果进行审查和迭代改进的机制	不改模型权重
Multi-Agent	多个 Agent 分工协作完成任务的架构	通信和调试成本远高于单 Agent
A2A	Agent 间通信的结构化接口约定，传递带 Schema 的任务、状态与验收信息	不是“让 Agent 用自然语言聊天”
Graph	由 Node、Edge、State 组成的工作流数据结构	Workflow 是思想，Graph 是表达
Loop	Graph 中允许回溯和重试的回边	必须配终止条件和成本上限
LLM Gateway	统一接入、路由、降级、限流、成本统计、审计的模型调用基础设施	不只是反向代理

四组关键边界

1. Agent / Chatbot / Workflow / RAG

维度	Chatbot	Workflow	Agent	RAG
核心问题	怎么把话说好	流程是否按图执行	下一步该做什么	去哪里找相关知识
控制权	模型直接回复	图结构预定义	模型动态决策	检索器 + 模型
外部动作	通常无	固定节点执行	按需调用工具	只读检索为主
失败模式	答错话	节点/边设计错误	死循环、乱调工具、目标漂移	召回差、上下文污染
典型产品	客服 FAQ 机器人	文章审核流水线	故障排查 Agent	企业知识库问答

一句话边界：**Chatbot 重对话，Workflow 重流程，Agent 重自主决策，RAG 重知识接入**；四者可以组合，但不能互相替代。

2. Function Calling / MCP / HTTP API / Skills

层	解决什么	类比
JSON Schema	参数“长什么样”	接口的字段定义
Function Calling	模型“想调什么、参数是什么”	调用请求的生成协议
HTTP API	服务之间“怎么传输”	REST 接口
MCP	AI 应用与工具之间“怎么发现和接入”	USB-C 统一接口
Agent Skills	一类任务“怎么做、何时做”	团队经验包 / SOP

判断口诀：模型生成的是调用意图，系统决定是否执行；MCP 管接入，Skills 管经验。

3. Memory / RAG / Context

概念	回答的问题	生命周期
Context	这一轮模型能看到什么	单次调用
Short-Term Memory	这个任务刚才发生了什么	当前任务
Long-Term Memory	过去积累了什么偏好与经验	跨任务持久化
RAG	外部知识库里有什么相关材料	按需检索

长期记忆可以借用 RAG 技术实现，但长期记忆还包括偏好、任务轨迹、经验教训的写入与演化；RAG 本身不做记忆演化。

4. Workflow / Graph / Loop / Agentic Workflow

- Workflow 是“固定流程”的抽象；
- Graph 是 Workflow 的数据结构表达：Node 执行、Edge 控制流、State 共享上下文；
- Loop 是 Graph 中的回边，用于重试、回溯、迭代；
- Agentic Workflow 是“固定骨架 + 局部自主”的组合。

概念关系图

```
1 flowchart LR
2   User[用户] -->|任务| Agent[AI Agent]
3   Agent --> LLM[LLM 推理与决策]
4   Agent --> MEM[Memory 记忆]
5   Agent --> TOOL[Tools 工具层]
6   TOOL --> FC[Function Calling 调用意图]
7   TOOL --> MCP[MCP 工具接入]
8   TOOL --> SK[Agent Skills 经验包]
9   Agent --> WF[Agentic Workflows]
10  WF --> GRAPH[Workflow / Graph / Loop]
11  MEM --> RAG[RAG 知识检索]
12  AGW[Agent Gateway] --> LLM
```

FAQ

- Q1：接了一个搜索工具的 Chatbot 是不是 Agent？** 如果每轮路径由代码写死、LLM 不决定“下一步做什么”，更接近 Workflow；只有当 LLM 能根据环境反馈持续决策并行动时，才算 Agent。
- Q2：RAG 是不是长期记忆？** 不是。RAG 是“查知识”，长期记忆还包括“记住偏好、经验、失败教训并更新”。RAG 只是长期记忆的一种实现手段。
- Q3：MCP 和 Function Calling 是不是二选一？** 不是。Function Calling 表达模型调用意图，MCP 标准化工具接入与发现。一个 MCP Server 暴露的工具，仍需用 JSON Schema 描述参数。
- Q4：有了 Agent Skills 还需要 Tool 吗？** 需要。Skills 组织经验与流程，Tool 提供原子能力；Skills 内部通常会调用 Tool。
- Q5：Multi-Agent 一定比单 Agent 强吗？** 不一定。多 Agent 带来并行与专业化，但通信、调试、成本会明显上升。先证明单 Agent 无法满足，再上多 Agent。

使用约定

- 写文档时优先使用本术语表定义；出现新术语先补充到术语表再使用。

- 面试题、架构图、设计文档中的“Agent”不得同时混用 Chatbot 与 Workflow 含义。
- 涉及协议时明确写全称：MCP、A2A、JSON Schema，不自行造词。
- 术语变更必须同步更新知识地图总索引.md 中对应节点。

相关文档

- [AI Agent 核心概念](#)：Agent Loop、范式、MCP/A2A/Skills
- [AI Agent 记忆系统](#)：Memory 与 RAG 的详细区别
- [大模型结构化输出](#)：JSON Schema与 Function Calling 落地
- [Agent 自主性分级](#)：从规则自动化到全自主的等级划分