

LLM 运行机制：Token、上下文窗口与采样参数怎么影响输出

Token 和上下文为什么决定成本与效果？

输入法输入“今天天气真”时，会自动建议“好”。大模型同理，只是参考的不是前几个字，而是前几千到几十万个字。每次只“补”一个 Token（文本碎片），再把该碎片加进上下文并预测下一个，循环直到生成完整回答。

这个过程叫做自回归生成（Autoregressive Generation）。

理解了自回归生成，后面所有概念都好办了：

- **Token**：模型每一步“补”的文本碎片。
- **上下文窗口**：模型在“补”之前能看到多少文本。
- **Temperature / Top-p**：模型选哪个候选碎片的策略。
- **Max Tokens**：允许模型最多“补”多少步。

Token 是模型的阅读单位。人类读中文逐字、读英文逐词，模型既不逐字也不逐词，而是通过 Tokenizer 把文本切成大小不等的碎片，每个碎片是一个 Token。

为什么不直接按字或按词切？因为模型需要在“词表大小”和“序列长度”之间取平衡：

- 每个汉字都是一个 Token，词表小、但序列长（模型要“补”更多步）。
- 每个词都是一个 Token，序列短、但词表会爆炸（中文词组太多了）。

所以实际用的是折中方案——**子词切分算法**（如 BPE、Unigram），高频词保留为整体，低频词拆成更小片段。

Token 可类比乐高积木：常用的“积木块”较大（如“你好”可能是一个 Token），不常用词会拆成更小的基础块。

Token 不是“一个字”或“一个词”的严格等价物：

- 英文可能一个单词被拆成多个 Token。
- 中文可能一个词被拆成多个 Token，也可能多个字合并成一个 Token（取决于词频与词表）。

工程上通常用**经验估算**做容量规划，用**实际 API 返回的 usage** 做精确计费与监控。

经验估算（仅用于粗略规划）：

- 英文：1 Token 大约对应 3~4 个字符（与文本类型相关）。
- 中文：1 Token 常见在 1~2 个汉字上下波动（与混排比例强相关）。

DeepSeek 官方数据：1 个英文字符约消耗 0.3 Token，1 个中文字符约消耗 0.6 Token。换算过来，1 个 Token 约等于 3.3 个英文字符或 1.7 个中文字符，与上述经验值吻合。


成本趋势提示：Token 成本与 Tokenizer 版本强相关。早期模型（如 GPT-3.5）中文压缩率较低（约 1 字 1.5~2 Token）。GPT-4o 使用 o200k_base Tokenizer（词表约 20 万），对中文压缩率有进一步提升；Qwen2.5 词表约 15 万，对中文常用词也有优化。实测数据因文本类型而异：新闻类约 1.5 字/Token，技术文档约 1.2 字/Token。

“趋近 1 字 1 Token”只适用于高频词汇，别拿它当成本估算基准。做预算前查一下当前模型版本的官方 Tokenizer 演示。

Token 划分直接影响模型理解能力。中文分词歧义和生僻字/低频专业术语的切分粒度，都会影响语义理解效果。

Token 化过程示例：

- 原文：你好，我是助手。
- 切分：[你好] [,] [我是] [助手] [。]
- 统计：原文 9 字符 → Token 数 5 个 → 压缩比约 1.8 倍



Token 化过程示例

注意：实际 Token 切分由模型供应商的 Tokenizer 实现，不同供应商对相同文本可能产生不同的 Token 序列。

OpenAI 官方网页端 Tokenizer 工具：[OpenAI Tokenizer](#)

特殊 Token：除了文本内容对应的 Token，模型内部还会使用一些特殊标记，这些也会计入 Token 总数：

特殊 Token	用途	示例
BOS (Beginning of Sequence)	标记序列开始	<s>
EOS (End of Sequence)	标记序列结束	</s>
PAD (Padding)	批处理时填充短序列	<pad>
工具调用标记	Function Calling 边界	<tool_call/>

这些特殊 Token 通常对用户不可见，但会占用上下文窗口。精确计数时建议使用官方 Tokenizer 工具而非手动估算。

多模态输入的 Token 开销

GPT-4o、Claude 3.5、Gemini 等模型已支持图片输入。图片不是“零成本”的——它会被转换成一批 Token，同样占用上下文窗口。

粗略估算规则：

模型	图片 Token 计算方式	一张 1024×1024 图片约等于
GPT-4o	按分辨率 + 细节模式	低细节 ~85 tokens，高细节 ~1105~765 tokens
Claude 3.5	固定 ~5 tokens (缩略图) 或 ~85 tokens (全图)	取决于图片模式
Gemini	按分辨率计算	~258 tokens (标准)

工程启示：

- 做多模态 RAG 时，要把图片 Token 也纳入预算。
- 批量处理图片时，注意首字延迟 (TTFT) 会显著增加。
- 如果只需要 OCR，考虑先用专门的 OCR 服务提取文字，再以纯文本形式送入模型。

上下文窗口的容量边界

上下文窗口是 LLM 的“工作记忆” (Working Memory)。它决定了模型在任何时刻可以处理或“记住”的文本量 (以 Token 为单位)。

- 对话连续性：决定模型能进行多长的多轮对话而不遗忘早期细节。
- 单次处理能力：决定模型一次性能够处理的最大文档、代码库或数据样本。

“模型支持 128K/200K/1M”指的是一次调用里能放进模型的总 Token 上限。大多数模型的上下文窗口包含输入与输出的总和，但部分供应商 (如 Google Gemini) 对输入和输出分别设限，使用前请查阅具体 API 文档。

上下文窗口往往被隐形成本占用：

- User Prompt：业务数据与指令。
- 多轮对话历史：过往的消息记录。
- RAG 检索片段：从外部知识库检索到的补充信息。
- 工具调用 Schema：函数定义与参数结构。
- 格式开销：特殊字符、换行符、Markdown 标记等。
- 模型生成的输出 Token：输出也占用上下文窗口。

因此，真正能塞进 Prompt 的有效业务内容往往远小于标称上限。

注意：上下文窗口 (Context Window) 最大生成长度。许多模型支持 128K 甚至 1M 输入，但单次输出上限因 API 而异。OpenAI Chat Completions API 使用 `max_tokens` 参数 (GPT-4o 最大 16K 输出)，部分新模型支持 `max_completion_tokens` (如 o1 系列)，DeepSeek V3 最大输出 8K。使用前需查阅具体模型的 API 文档。

思维链模式的多轮对话处理：思维链模型 (如 DeepSeek-R1) 的 `reasoning_content` (思考过程) 通常不会被自动包含在下一轮对话的上下文中，只有 `content` (最终回答) 会参与后续对话。

这意味着：

- 无需为思考过程额外占用上下文窗口。
- 如果后续对话需要参考之前的推理过程，需要手动将 `reasoning_content` 拼接到消息历史中。
- 部分供应商的 SDK 会自动处理这一差异，建议查阅具体文档确认。

长上下文背后的计算约束

上下文窗口并非越大越好，它受限于 Transformer 架构的自注意力机制 (Self-Attention)：

- 计算成本平方级增长：计算需求与序列长度呈平方级关系 ($O(N^2)$)。输入 Token 翻倍，处理能力需求可能变为 4 倍。

- 推理延迟增加：上下文变长后，模型生成每个新 Token 时需要关注的历史 Token 变多，首字延迟 TTFT 会显著增加。

- 安全风险增加：更长的上下文意味着更大的攻击面。

工程优化手段：FlashAttention、GQA/MQA、Sliding Window Attention、Chunked Attention 等技术已显著降低长上下文的计算和显存开销。但 $O(N^2)$ 的理论复杂度仍是上限扩展的根本瓶颈。

上下文窗口溢出时的真实表现：当上下文接近上限或内容过长时，常见现象包括：

- 模型忽略早期约束：System Prompt 里要求“必须输出 JSON”，但因距离生成点太远，注意力不足导致被忽略。

- “中间丢失”现象：即使在 1M 窗口模型中，模型对开头和结尾的信息最敏感，对中间部分的信息召回率显著下降。


在长文本生成任务中，后半段开始总结/扩写/跑题。

- RAG 失效：检索文档过多，关键信息被稀释；或被截断导致证据链断裂。

- 成本与延迟激增：1M 上下文会导致 TTFT 显著增加，且 Token 成本呈线性增长。

输入 Token 与输出 Token 的计费差异

大多数供应商对输入 Token 和输出 Token 采用不同的计费标准，通常输出价格是输入的 2~4 倍：



上下文窗口 (Context Window) = LLM 的「工作记忆」

- System Prompt：调节模型行为的系统指令 (对用户隐藏，但占用窗口)。

模型	输入价格 (/1M Tokens)	输出价格 (/1M Tokens)	输出/输入比
GPT-4o	\$2.50	\$10.00	4x
Claude 3.5 Sonnet	\$3.00	\$15.00	5x
DeepSeek V3	¥0.5	¥2.0	4x
DeepSeek-R1	¥4.0	¥16.0	4x

工程启示：

- 长 Prompt + 短输出 = 更经济的调用方式。
- RAG 场景要控制检索片段数量，避免输入 Token 激增。
- 思维链模型的 reasoning tokens 通常按输出价格计费，成本更高。

Prompt Caching 的省钱逻辑

当请求中存在大量重复的固定前缀（如 System Prompt、长 RAG Context），可以用 **Prompt Caching** 显著降低成本。

原理：供应商会缓存请求中“可复用的前缀部分”。下次请求如果前缀相同，这部分就不重新计费，只收“缓存读取”的费用（通常是正常价格的 10%~50%）。

典型适用场景：

- 多轮对话（System Prompt + 历史 Message 不变）。
- RAG 应用（检索片段重复率高）。
- 批量评估（同一份 System Prompt，不同的简历/文章）。

各供应商支持情况：

供应商	功能名称	缓存时长	缓存命中折扣
OpenAI	Prompt Caching	5~10 分钟	输入价格约 50
Anthropic	Prompt Caching	5 分钟	输入价格约 10
DeepSeek	Context Caching	10~30 分钟	输入价格约 25

工程建议：

1. 把不变的内容放前面（System Prompt、工具定义、RAG Context），把变化的内容放后面（User Prompt）。
2. 监控 `cache_read_tokens` 和 `cache_creation_tokens` 指标，验证缓存命中率。
3. 批量任务尽量在缓存时间窗口内完成。

一次调用的 Token 预算公式

把“上下文窗口”当成一个固定容量的桶，下图展示了一个典型调用的 Token 预算分配：

此分配仅为示意，实际比例需根据业务场景动态调整。

最实用的预算方式是：

`window_input_tokens + max_output_tokens`

对于思维链模型，公式应调整为：

`window_input_tokens + reasoning_tokens + max_output_tokens`

其中 `reasoning_tokens`（思考链 Token 数）难以精确预估，建议按 `max_output_tokens` 的 2~3 倍预留。

其中 `input_tokens` 至少包含：

- system prompt（含 schema / 工具定义）
- user prompt（含变量替换后的实际文本）
- 历史消息（多轮对话时）
- RAG context（如果拼进来了）

工程上建议反过来做预算（因为输出经常更可控）：

1. 先定 `max_output_tokens`（结构化输出通常不需要很长）。

2. 再为输入预留安全边际（例如再留 10%~20% 给供应商额外开销）。

3. 超预算时，用可解释的策略“减输入”而不是“赌模型会自我约束”：

- 优先减少 RAG 的 Top-K 或做片段去重。

- 对长字段做摘要/截断（如简历、长回答）。

- 多段任务拆成多次调用（分批评估、两阶段生成）。

采样参数如何影响输出稳定性？

从 logits 到概率采样

模型每一步会给词表中每个候选 Token 打一个分数（内部叫 **logits**），分数越高说明模型越觉得这个词应该出现在这里。

举个例子，假设模型正在补全“今天天气真 ____”，它可能给出这样的分数：

候选 Token	原始分数 (logit)
好	5.0
不错	3.2
棒	2.1
糟糕	0.5
紫色	-8.0

但原始分数不是概率——需要经过一次数学变换（**softmax**）才能变成每个候选被选中的概率。变换后大致是：

候选 Token	概率
好	62
不错	20
棒	10
糟糕	5
紫色	0

最后，模型按这个概率分布“抽签”（采样），决定输出哪个 Token。

解码参数（Temperature、Top-p、Top-k 等）就是在这个“打分 → 概率 → 抽签”的过程中施加控制：

- Temperature：调整概率分布的“形状”，让高分选项更突出，或者让各选项更均匀。

- Top-p / Top-k：直接砍掉不靠谱的候选项，缩小“抽签池”。

- Penalty 系列：对已经出现过的词降分，防止“复读机”。

Temperature 的 “冒险程度”

- 模型版本更新（底层权重变化）。
- 跨区域调用（不同集群可能部署不同版本）。
- Temperature 参数：控制模型输出的随机性
- Top-p 采样（即使 T=0，若 Top-p<1 仍有随机性）。

Temperature 参数：控制模型输出的随机性

建议在 CI/CD 中仅将 LLM 调用用于冒烟测试，核心逻辑仍依赖 Mock。

Top-p 与 Top-k 的 “抽签池”

Temperature 调整的是概率分布的形状，但不管怎么调，词表里所有 Token 理论上都有被选中的可能。Top-p 和 Top-k 则更直接——把不靠谱的候选直接踢出抽签池。

还是用 “今天天气真 ____” 的例子：

候选 Token	概率	累计概率
好	62	
不错	20	
棒	10	
糟糕	5	
紫色	0	

- Top-k = 3：只保留概率最高的 3 个候选（好、不错、棒），在这 3 个里重新分配概率后采样。“糟糕”和“紫色”直接出局。
- Top-p = 0.9：从高到低累加概率，保留累计刚好达到 90% 的最小集合。这里 “好 + 不错 + 棒 = 92%”，所以保留这 3 个。如果某个场景下头部更集中（比如第一名就占了 95%），Top-p 会自动只保留 1 个——比 Top-k 更灵活的地方就在这。

两者的区别：Top-k 固定保留 k 个，不管概率分布长什么样；Top-p 根据概率自适应调整候选数量。实践中 Top-p 更常用，因为它能自动适应不同的概率分布。

常见组合：

组合	效果	适用场景
T=0（贪婪解码）	永远选最高分，完全确定	结构化输出、可复现场景
低温 + Top-p=0.9	相对稳定，但允许措辞上有些变化	分析报告、摘要
中高温 + Top-p=0.95	多样性较高，但排除了极端离谱选项	创意写作、对话

注意：贪婪解码虽然最稳定，但可能更容易陷入重复循环。

停止条件与截断风险

工程上需要意识到两点：

- **Max Tokens 是硬上限**：到上限会被强制截断，模型正写到一半也会被“掐断”。常见后果：JSON 缺右括号、列表缺最后几项、句子写了一半。
- **Stop Sequences（停止词）是软切断**：可以指定一些字符串（如 “\n\n” 或 “ ” “ ”），模型生成到这些内容时会自动停止。但如果 stop 设计不当，可能提前截断关键字段。

结构化输出场景要把 “截断风险” 当成一类失败路径来设计缓解策略。

思维链模式的 Token 计算差异：对于支持思维链的模型（如 DeepSeek-R1），max_tokens 通常包含思考过程 + 最终回答两部分。例如设置 max_tokens=8192，模型可能在思考链上消耗 5000 tokens，最终回答只剩 3192 tokens 的预算。

不同供应商的默认值和上限差异较大：DeepSeek-R1 默认 32K、最大 64K；OpenAI o1 系列的输出上限也高于普通模型。使用前务必查阅具体模型的 API 文档。

Penalty 与复读问题

可能遇到过模型反复输出同一句话，或者在长回答里不断重复相同观点。Penalty 参数用来缓解这类问题，它们在解码时降低已出现 Token 的分数：

Temperature 的工作原理很简单：在 softmax 之前，先把所有分数除以温度值 T。

$$p(t) = \text{softmax}(z_t / T)$$

- T = 1：保持原始分布。
- T < 1：分布更尖锐，更倾向选择高概率 Token（更“稳”）
- T > 1：分布更平坦，低概率 Token 更容易被采样到（更“野”）

还是用 “今天天气真 ____” 的例子：

- T = 0.2（低温）：分数差距被放大（都除以 0.2，等于乘以 5），原本就领先的 “好” 概率飙升到 ~98%，几乎每次都选它。
- T = 1.0（默认温度）：保持原始分布不变，“好” 62%、“不错” 20%... 按正常概率采样。
- T = 1.5（高温）：分数差距被缩小（都除以 1.5），“好” 概率降到 ~35%，“棒”、“不错” 甚至 “糟糕” 都有更大机会被选中。

温度越低，输出越确定；温度越高，输出越随机。

工程建议（经验值，非硬规则）：

场景	推荐温度	说明
结构化提取 / JSON 输出	0 ~ 0.3	配合严格 schema + 解析失败重试策略
评估 / 分析 / 代码评审	0.4 ~ 0.8	平衡确定性与表达多样性
创作类内容（文案、头脑风暴）	0.8 ~ 1.2+	增加多样性，但要承担格式一致性风险

追求确定性？若需单元测试幂等或结果复现，仅设 Temperature=0 不够（GPU 浮点误差仍可能导致非确定性）。建议同时配置 seed 参数（如 OpenAI/DeepSeek 支持）。

即使配置 seed，以下情况仍可能导致结果不一致：

参数	作用	通俗理解
Repetition Penalty	降低所有已出现 Token 的概率	“说过的词，再说就扣分”
Presence Penalty	只要 Token 出现过就扣分（不看次数）	“鼓励聊新话题”
Frequency Penalty	Token 出现次数越多扣分越重	“同一个词说了三遍？重罚”

工程陷阱：

- 结构化输出别乱加 Penalty：JSON 里字段名（如 "name"、"score"）需要反复出现，加了 Repetition Penalty 可能把必须出现的字段名也“惩罚掉”，导致输出残缺。
- RAG 问答别加 Presence Penalty：它会鼓励模型“说点新东西”，反而降低对检索内容的忠实度，增加幻觉风险。

保守建议：如果不确定这些参数的精确语义（不同供应商定义可能不同），建议保持默认值。用低温 + 更强 Prompt 约束 + 更短输出来获得稳定性，比调 Penalty 更可控。

思维链模式的参数限制

部分模型（如 DeepSeek-R1、OpenAI o1）支持“思维链模式”，在生成最终回答前会先输出一段内部推理过程。这类模型有特殊的参数约束：

不支持的采样参数：思维链模式下，以下参数通常被忽略：

- temperature、top_p：采样控制参数。
- presence_penalty、frequency_penalty：惩罚参数。

原因：思维链模式的设计目标是让模型“自由思考”，采用模型内部固定的采样策略，用户传入的采样参数会被忽略。工程建议：

- 调用思维链模型时，不要依赖上述参数控制输出风格。
- 若需要更稳定的输出格式，应通过 Prompt 约束而非采样参数。
- 关注模型返回的 reasoning_content 字段（思考过程）与 content 字段（最终回答）的区别。

流式输出与首字延迟

默认情况下，API 会等模型生成完所有内容后一次性返回。流式输出则是边生成边返回——模型每生成一个（或几个）Token，就立刻推送给客户端，用户更早看到内容开始出现。

核心价值：改善用户体验，降低首字延迟（TTFT，Time-To-First-Token）。

常见误解澄清：

- 流式输出更快——总耗时（E2E latency）不一定下降，模型生成的总 Token 量相同。
- 流式输出更省钱——Token 计费不变，仍然受限流/配额影响。
- 如果需要结构化输出（如 JSON），流式场景要考虑“半成品 JSON”在前端/网关层的处理。

Logprobs 与置信度排查

部分 API（如 OpenAI）支持返回每个生成 Token 的对数概率（logprobs），可以理解为模型对该 Token 的“确信程度”。logprob 越接近 0，模型越确信；值越小（如 -5.0），说明模型越“犹豫”。

工程应用场景：

- 置信度评估：提取“金额：1000”时，若对应 Token 的 logprob 很低，说明模型不太确定，可能需要人工复核。
- 异常检测：监控生产环境中模型输出的平均 logprob，若突然下降可能提示 Prompt 漂移或输入数据异常。
- 多候选对比：获取 Top-N 候选 Token 及其概率，用于纠错或二次排序。

注意事项：logprobs 会增加响应体积，且并非所有供应商都支持。使用前请查阅 API 文档。

采样参数配置建议

场景	Temperature	Top-p	Penalty	其他建议
JSON / 结构化输出	0 ~ 0.3	1.0	保持默认	配合 Strict Mode + 重试策略
代码评审 / 技术分析	0.4 ~ 0.7	0.9	保持默认	结合 CoT Prompt
多轮对话	0.6 ~ 0.8	0.9	适度开启	控制历史消息长度
创意写作 / 头脑风暴	0.8 ~ 1.2	0.95	按需开启	接受输出多样性，做好后处理
思维链模型	—（不支持）	—	—	通过 Prompt 控制，非采样参数

总结

核心是三个维度的工程权衡：

- Token 是成本与性能的物理标尺**：它不仅决定计费账单和推理延迟，更决定模型对文本的理解粒度。做容量规划时，必须按 Token 算账，而不是按字数算账。
- 上下文窗口是极其稀缺的资源**：哪怕模型宣称支持 1M 上下文，也不意味着可以毫无节制地堆砌数据。为 Prompt、RAG 检索片段、历史对话和输出预留做好严格的 Token 预算分配，是走向生产环境的必修课。
- 采样参数是业务场景的调音台**：如果追求稳定的 JSON 输出，就果断压低 Temperature 并配合严格的 Schema；如果需要创意与头脑风暴，再适度放开 Temperature 和 Top-p。不要迷信默认参数，要根据业务的容错率来定制。

掌握参数与原理后，Agent 编排、RAG 检索和 MCP 工具调用的本质，是更精准地调度 Token 并管理上下文窗口。