

2026 大模型面试题 | Agent 面试题 | RAG 面试题 | AI 应用开发面试指南（含答案与图解）

AI 应用开发面试和传统后端面试不太一样。传统后端面试更多围绕 Java、JVM、并发、MySQL、Redis、消息队列、分布式和系统设计展开。AI 应用开发面试除了这些基础，还会继续追问：

- 大模型 Token 是怎么计算的？上下文窗口越大越好吗？
- Function Calling 和 MCP 有什么区别？工具调用怎么做权限控制？
- RAG 召回率低怎么排查？Chunk 怎么切？Rerank 解决什么问题？
- Agent 的 Memory 怎么设计？长任务上下文溢出怎么办？
- 如何设计一个生产级 AI 应用？模型网关、评测、可观测怎么做？

这些题不是背几个术语就能过的。AI 应用开发面试更看重的是：**你能不能把大模型、RAG、Agent、工具调用和系统设计放到真实工程里理解。**所以，这篇文章会作为 AI 面试题的总入口。你可以先通过这里建立知识地图，再进入具体模块刷题和回到原文补底层理解。

面试题目录

面试题模块	适合重点复习的人群	主要覆盖内容
大模型基础面试题总结	所有准备 AI 应用开发面试的人	Token、上下文窗口、采样参数、API 调用、流式输出、结构化输出、Function Calling、AI 应用评测
AI Agent 面试题总结	准备 Agent、工具调用、工作流相关岗位的人	Agent Loop、Memory、Prompt Engineering、Context Engineering、MCP、Agent Skills、Harness Engineering、Workflow、Graph、Loop
RAG 面试题总结	准备知识库问答、企业 AI 应用、搜索增强生成相关岗位的人	RAG 基础、Embedding、向量数据库、Chunk 策略、Hybrid Search、Query Rewrite、Rerank、GraphRAG、知识库更新与评测
AI 系统设计面试题总结	2 年以上开发者、准备社招和系统设计面试的人	生产级 AI 应用架构、模型网关、Prompt 管理、RAG、Memory、Tool Calling、可观测、评测、安全合规、实时语音 Agent

这 4 篇是“面试题入口”，每篇都会告诉你：

- 这个模块的面试官到底想考什么。
- 高频题有哪些。
- 每组题背后应该掌握哪些关键点。
- 常见扣分点是什么。
- 应该回到哪篇原文继续深入学习。

建议你不要把它们当作纯题库看，而是当作“复习路线图”。题目只是入口，真正要掌握的是题目背后的工程判断。这里说的“含答案与图解”，不是把所有内容压缩成几句标准答案，而是每篇面试题都会提供答题思路、关键点、扣分点和参考文章。更完整的图解和推导放在对应专题原文里，方便你从面试题继续深入学习。

AI 应用开发面试考什么？

AI 应用开发面试和传统后端面试最大的区别是：它不只问你会不会调用接口，而是问你能不能把 AI 能力接入真实系统。可以粗略分成三层。

第一层：大模型基础认知

这一层是所有 AI 应用开发岗位都绕不开的基础。面试官通常会问：

- Token 是什么？为什么中文、英文、代码消耗的 Token 不一样？
- 上下文窗口有什么限制？长上下文为什么不一定更好？
- Temperature、Top-P、Top-K 分别控制什么？生产环境怎么调？
- 大模型为什么会产生幻觉？有哪些工程缓解方式？
- JSON Mode、Structured Outputs、Function Calling 有什么区别？

这些题看起来基础，但真正要考的是工程认知。你不需要在普通应用开发面试里手推 Transformer，但必须知道这些参数会如何影响成本、延迟、稳定性、结构化输出和线上质量。如果你发现自己只能背定义，讲不出生产里的影响，建议先看：大模型基础面试题总结。

第二层：AI 应用组件能力

这一层是和“只会调 API”拉开差距的地方，主要包括 RAG、Agent、Prompt、Context、MCP、工具调用等。高频题包括：

- RAG 召回率低怎么排查？是 Chunk 问题、Embedding 问题，还是排序问题？
- Hybrid Search、Query Rewrite、Rerank 分别解决什么问题？
- Agent Loop 是什么？和普通工作流有什么区别？
- Agent Memory 怎么设计？短期记忆和长期记忆怎么区分？
- MCP 和 Function Calling 有什么区别？生产级 MCP Server 怎么做安全治理？
- Prompt Engineering 和 Context Engineering 到底差在哪？

这些题的共同点是：面试官不满足于听概念，而是会追问“你怎么落地”“出了问题怎么排查”“为什么这么选”。

如果你正在准备企业知识库、智能客服、Agent 工作流、AI 编程助手这类方向，建议重点看：

- RAG 面试题总结
- AI Agent 面试题总结

第三层：AI 系统设计

对于社招和有项目经验的候选人，这一层几乎必问。

面试官可能会直接给你一个开放题：

- 如何设计一个企业级 AI 知识库问答系统？
- 如何设计一个生产级 Agent 平台？
- 如何设计一个模型网关，支持限流、熔断、降级和成本统计？
- 如何设计 AI 应用评测体系？Golden Set、LLM-as-Judge、Trace 回放怎么做？
- 如何设计一个实时语音 Agent？打断、低延迟、状态机怎么处理？

这类题考的是架构能力。你不能只说“用 LangChain 搭一个 RAG”，而要能讲清入口层、编排层、Prompt/Context、RAG、Memory、Tool、模型网关、可观测、评测、安全合规这些模块分别解决什么问题。

系统设计题建议直接看：AI 系统设计面试题总结。

怎么用这套面试题复习？

这套面试题更适合“先建立框架，再回到原文深入”的方式。

1. 先用面试题建立知识地图

先快速过一遍 4 篇面试题，不要求马上记住所有答案。第一遍的目标是知道 AI 应用开发面试会问哪些方向：

- 大模型基础
- RAG
- Agent
- MCP 和工具调用
- Prompt 和 Context Engineering
- AI 系统设计
- AI 应用评测
- 实时语音 Agent

这一步能帮你避免复习时东一榔头西一棒子。

2. 再回到原文补底层理解

每道题后面都贴了参考文章链接。遇到答不上来的题，不要急着背标准答案，先回到原文看完整逻辑。

比如：

- Token、上下文窗口、采样参数不清楚，就看《LLM 运行机制》。
- Function Calling、Structured Outputs、MCP 边界不清楚，就看《大模型结构化输出详解》和《万字拆解 MCP 协议》。
- RAG 效果优化说不清楚，就看《万字详解 RAG 检索优化》。
- 生产级 AI 应用架构说不清楚，就看《AI 应用系统设计》。

面试题负责帮你定位考点，正文负责帮你补完整的因果链。

3. 最后用“工程表达”组织答案

AI 面试题不要只答“是什么”，建议按这个结构组织：

1. **先解释概念**：一句话讲清楚它是什么。
2. **再说明问题**：它在真实系统里会带来什么影响。
3. **接着给方案**：生产环境怎么设计、排查、优化或治理。
4. **最后讲边界**：什么场景适用，什么场景不适用。

比如问“RAG 召回率低怎么优化”，不要直接背 Hybrid Search、Rerank、Query Rewrite。更好的回答是：

先判断正确证据有没有进入候选池；如果没有，排查文档解析、Chunk、Embedding、Metadata、Query Rewrite；如果进入了但排得靠后，再考虑 Hybrid Search、Rerank、候选池大小和融合权重；如果证据进了上下文但答案仍然错，再看 Prompt、上下文位置、模型是否忠实使用证据和评测样本。

这类回答更像真的做过系统。

不同经验阶段怎么复习？

先说结论：**不同经验阶段不是“看不看某个模块”的区别，而是掌握深度不同。**

即使是应届生，也建议至少了解 Agent 和 AI 系统设计的基本问题。现在很多校招项目、实习项目都会写智能客服、知识库问答、AI 助手、AI 编程工具，如果你完全不了解 Agent Loop、RAG 链路和生产级架构，面试官一追问就容易露怯。

更合理的复习方式是：所有人都要建立完整地图，只是深度分层。

应届生和 0-1 年

目标不是把所有工程细节都背下来，而是能把 AI 应用开发的基本链路讲清楚。

- 大模型基础面试题总结
- AI Agent 面试题总结
- RAG 面试题总结
- AI 系统设计面试题总结

这个阶段建议重点做到：

- 大模型基础：能讲清 Token、上下文窗口、采样参数、结构化输出为什么会影工程稳定性。
- RAG：能画出“文档处理 -> Chunk -> Embedding -> 向量库 -> 检索 -> 生成”的基本链路，并知道召回不准不能只改 Prompt。
- Agent：能说明 Agent 和普通 Chatbot、Workflow 的区别，知道 Agent Loop、Memory、Tools 是什么。
- 系统设计：能用简单语言描述一个 AI 知识库问答系统包含哪些模块，比如鉴权、RAG、模型调用、日志和评测。

应届生不一定要讲出复杂的模型网关、灰度回放和多 Agent 协作，但要表现出你不是只会复制 Demo，而是知道 Demo 到生产之间有工程差距。

2-3 年

这个阶段要从“知道链路”升级到“能定位问题、能做取舍”。

- 大模型基础面试题总结
- AI Agent 面试题总结
- RAG 面试题总结
- AI 系统设计面试题总结

这个阶段建议重点做到：

- 大模型基础：能讲清 API 调用链路、幂等、限流、重试、结构化输出失败处理。

- RAG: 能按文档处理、召回、排序、上下文、生成、评测这几段排查问题。
- Agent: 能讲清 Agent Loop、Memory、MCP、Function Calling、Skills 的边界和组合方式。
- 系统设计: 能讲一个生产级 AI 应用的核心模块, 至少覆盖 Prompt 管理、RAG、Tool Calling、安全和可观测。

面试官会更关注你是否能把 AI 能力接入真实业务系统。比如“知识库更新后旧答案还在怎么办”“工具调用失败怎么降级”“如何证明新 Prompt 比旧 Prompt 更好”, 这些问题要能给出工程化回答。

3 年以上

这个阶段系统设计会成为重点, 但大模型基础、RAG 和 Agent 仍然不能丢。区别是: 你不能只讲单点技术, 要能讲完整架构、治理策略和演进路线。

- 大模型基础面试题总结
- AI Agent 面试题总结
- RAG 面试题总结
- AI 系统设计面试题总结

这个阶段建议重点做到:

- 架构设计: 能拆出入口层、编排层、Prompt/Context、RAG、Memory、Tool、模型网关、评测观测和安全合规模块。
- 治理能力: 能讲清模型路由、fallback、Token 成本归因、Prompt 版本管理、权限隔离、审计日志。
- 质量闭环: 能说明 Golden Set、Trace 回放、线上灰度、LLM-as-Judge 和人工复核怎么配合。
- 风险控制: 能处理 Prompt 注入、工具越权、隐私泄露、RAG 权限过滤、模型供应商故障等问题。

这个阶段最容易被追问“如果上线后效果变差, 你怎么定位?”“如果模型供应商限流, 你怎么降级?”“如果 Agent 工具调错了怎么办?”“如何证明新 Prompt 比旧 Prompt 更好?” 这些问题都需要工程闭环, 而不是概念答案。

这些面试题和 AI 专栏是什么关系?

可以这样理解:

- 这篇文章是入口, 帮你快速定位高频考点。
- AI 应用开发专栏是正文, 帮你把每个考点背后的原理、工程细节和实践方案讲透。

面试题页不会把所有答案都写成几万字, 否则会变得很难复习。它更像索引和路线图: 告诉你该问什么、该掌握什么、该回到哪篇文章继续学。

如果你只想临时抱佛脚, 可以先刷 4 篇面试题; 如果你想真正把 AI 应用开发这块补扎实, 建议按专题把原文也读完。

后续会继续更新

AI 应用开发还在快速变化, 面试题也会继续更新。后面如果出现新的高频方向, 比如多模态 Agent、端侧模型、AI Coding 工程化、MCP 生态实践、企业级评测平台, 我也会继续补到这套面试题里。

如果你发现某个高频题还没覆盖, 也欢迎在项目 issue 区留言。